

Maths pour la Data Science

Master 1 – 2025/2026


Paul Ouvrard – paul.ouvrard@scalian.com

Statistiques

18/06/2026



Introduction aux statistiques



QU'EST-CE QUE LA STATISTIQUE ?

Qu'est-ce que la statistique?

- L'origine du mot « statistique » remonte au latin classique *status* qui signifie « état »
- **Définition classique :** « *La Statistique est l'ensemble des méthodes qui ont pour objet la collecte, le traitement et l'interprétation de données d'observation relatives à un groupe d'individus ou d'unités.* »
- À noter :
 - **La Statistique** (souvent avec une majuscule) = science permettant de décrire et d'analyser données
 - **Une statistique** = grandeur calculée à partir des observations recueillies (par exemple : moyenne d'âge des élèves d'une même classe, etc.)

UTILISATION DE LA STATISTIQUE

Les statistiques sont utilisées :

- Dans **tous les secteurs d'activité** :
 - **Géophysique** : prévisions météorologiques, climatologie, pollution, etc.
 - **Démographie** : prévisions d'évolution de la population, etc.
 - **Marketing** : sondages, advertising, profilage, etc.
 - **Physique** : mécanique statistique, thermodynamique statistique, etc.
 - **Médecine et psychologie** : diagnostic, validité des traitements, analyse des maladies, etc.
 - **Assurance et en finance** : calcul des risques, prévisions, etc...
 - **Industrie** : fiabilité, contrôle qualité...
 -
- **Partout et tout le temps en Data Science.**
 - Exploration de donnée : décrire le jeu de données, étude de corrélation entre deux variables, etc.
 - Pré-traitement : détection d'*outliers*, imputation de données manquantes, etc.
 - Entraînement : choix des *features*, modèle sous-jacent, etc.
 - Évaluation : choix des métriques et analyses
 - Visualisation : définitions de graphiques pour expliquer les performances
 - Explicabilité : importance des variables (valeurs SHAP), etc.

VOCABULAIRE

The diagram shows a table with four columns: Prénom, Nom, Âge, and Étiquette. The first four rows represent individuals: Bob Smith (12, Anomalie), Roger Dupont (45, Normal), Kevin Durant (52, Anomalie), and Robert Dupond (45, Normal). Annotations include: 'Variables' pointing to the 'Âge' and 'Étiquette' headers; 'Échantillon' pointing to the first four rows; 'Individu' pointing to a single row; and 'Observations de la variable « âge »' pointing to the 'Âge' column values.

Prénom	Nom	Âge	Étiquette
Bob	Smith	12	Anomalie
Roger	Dupont	45	Normal
Kevin	Durant	52	Anomalie
Robert	Dupond	45	Normal

- Sélection d'un sous-ensemble d'individus pour créer le jeu d'entraînement : **échantillonnage**
- Le modèle entraîné est appliqué sur la **population**

VOCABULAIRE

- L'ensemble de personnes ou d'objets équivalents étudié s'appelle la_____.
- Chaque objet d'une population s'appelle un _____ (ou unité statistique).
- Les caractéristiques que l'on mesure s'appellent des _____.
- Les mesures s'appellent des _____.
- La série d'observations recueillies s'appelle _____.
- La partie des individus étudiés (un ou plusieurs) s'appelle _____.
- Le recueil d'un échantillon à partir de la population initiale se fait par des techniques statistiques, appelées _____.

VOCABULAIRE

- L'ensemble de personnes ou d'objets équivalents étudié s'appelle la **population**.
- Chaque objet d'une population s'appelle un **individu** (ou unité statistique).
- Les caractéristiques que l'on mesure s'appellent des **variables**.
- Les mesures s'appellent des **observations**.
- La série d'observations recueillies s'appelle **série statistique**.
- La partie des individus étudiés (un ou plusieurs) s'appelle **échantillon**.
- Le recueil d'un échantillon à partir de la population initiale se fait par des techniques statistiques, appelées **méthodes d'échantillonnage**.

DÉFINITIONS DE BASE

Statistique descriptive versus inférentielle

- L'objectif de la **statistique descriptive** est de **décrire** une population, c'est-à-dire de représenter par les statistiques les données disponibles (quand elles sont suffisamment nombreuses).
 - Exemples d'utilisation : reporting, visualisation (graphiques), nettoyage de données (*data cleaning*) comme la détection d'*outliers* etc.
 - En résumé : donner une image claire de la situation à partir d'indicateurs comme la moyenne, l'écart-type etc., des graphiques, etc.
- L'**inférence statistique (statistique inférentielle)** est l'ensemble de techniques permettant **d'inférer** les caractéristiques de la population à partir de celles d'un échantillon par une mesure de la probabilité des caractéristiques.
 - Exemples d'utilisation : sondage pour les élections, enquête ménage-déplacement, tester l'efficacité d'un nouveau médicament sur un groupe de patients, etc.
 - En résumé : on cherche à généraliser ce que l'on a observé sur l'échantillon, prédire, prendre des décisions avec une marge d'erreur via des tests d'hypothèses, intervalles de confiance, des régressions etc.

POURQUOI LES STATISTIQUES DESCRIPTIVES ?

- En statistiques, on est en général en présence d'un **grand nombre de données**
- Il n'est pas évident de les manipuler et visualiser
- Il faut donc calculer quelques valeurs qui vont permettre d'analyser les données d'une population ou de comparer plusieurs populations:
 - On synthétise l'information via des **indicateurs statistiques**
 - Parfois ils sont extrêmement concis, réduits à un nombre : c'est le cas des valeurs de **position** (moyenne, médiane, etc.) et des valeurs de **dispersion** (étendue, écart-type, etc.)
- Les moyens informatiques permettent aujourd'hui d'étudier plusieurs variables simultanément
 - Identifier des liens
 - L'étude de **corrélation** mesure l'intensité du lien entre deux variables (si une variable augmente, est-ce que l'autre augmente aussi ?)
 - Prédire des comportements
 - Un modèle de **régression** permet d'estimer (prédire) à partir de données d'entraînement
 - Simplifier les données complexes
 - **Analyse en composantes principales** pour réduire la dimensionnalité (i.e., le nombre de variables) sans perdre l'information essentielle
 - **Analyse en composantes indépendantes** pour faire de la séparation de sources (e.g., *cocktail party problem*)
 - **Exploration de données**, par exemple pour identifier des motifs cachés (*pattern recognition*)


STATISTIQUES ET PROBABILITÉS

- **Probabilités** : théorie permettant de modéliser des phénomènes aléatoires
- **Statistiques** : repose sur l'observation de données issues d'un phénomène concret

Rôle de la théorie des **probabilités** dans les problèmes de statistique :

- Les caractéristiques d'une grande population peuvent être considérées comme des **variables aléatoires**
- Les observations recueillies dans l'échantillon peuvent être considérées comme des **réalisations** de ces variables
- Un échantillon représentatif permet d'approcher les caractéristiques probabilistes théoriques de toute la population à l'aide des statistiques calculées à partir de cet échantillon
- Le rôle des probabilités est très majoritairement pour la **statistique inférentielle**.

Notions de base : variables et histogrammes



VARIABLES QUALITATIVES ET QUANTITATIVES

- Les variables **quantitatives** mesurent des quantités, et on peut généralement les ordonner
 - Variables **discrètes** : ne prennent que des valeurs finies qu'on peut dénombrer
 - Variables **continues** : peuvent prendre un ensemble continu (infini) de valeurs dans un intervalle
- Une variable **qualitative** (ou **catégorielle**) mesure des états (catégories), qui généralement ne peuvent pas être ordonnés (on ne peut pas dire de l'un qu'il est inférieur ou égal à l'autre)
- **À noter** : le fait qu'une variable soit numérique n'implique pas nécessairement qu'elle est quantitative (exemple : le code postal)
- **À noter** : les variables statistiques sont analysées différemment selon leur nature (quantitative, qualitative).

EXEMPLE



- **Population** : employés d'une entreprise
- **Individu** : un employé
- **Échantillon** : employés que nous avons interviewés
- **Variables observées** : rétribution, sexe, âge, ancienneté, niveau de formation
 - Variables **catégorielles (qualitatives)** : sexe, niveau de formation
 - Variables **discrètes** : âge, ancienneté
 - Variables **continues** : rétribution

salarié	rétribution	sexe	âge	ancienneté	niveau_formation
1	21894.4	F	42	3	B
2	38539.2	M	54	10	B
3	38177.6	M	47	10	A
4	38738.4	M	47	1	B
5	36481.6	M	44	5	B
6	35226.4	M	42	10	A
7	15516.0	M	30	5	A
8	15516.0	F	52	6	A
9	30499.2	M	48	8	A
10	15180.0	F	58	4	A
11	38539.2	M	46	4	C
12	42812.0	M	36	8	C
13	47035.2	M	49	10	B

FRÉQUENCES ET HISTOGRAMME

- Les observations d'une variable statistique d'un tableau de données peuvent être regroupés par valeurs pour être visualisées efficacement
- Dans le cas de variables **discrètes ou catégorielles**, il est possible de calculer la **fréquence** de chaque valeur :
 - Fréquence absolue (ou effectif) n_i** : le nombre d'individus qui ont la même valeur x_i
 - Fréquence relative f_i** : $f_i = n_i/N$ avec $N = \sum n_i$ et donc $\sum f_i = 1$
- Pour visualiser les fréquences d'une variable, on utilise un **histogramme** (diagramme en bâtons)
- En abscisses : les modalités (valeurs prises par la variable) ordonnées de façon arbitraire pour variables catégorielles ou croissante pour les variables discrètes discrètes
- En ordonnées: des rectangles dont la longueur est proportionnelle aux fréquences de chaque modalité







salarié	rétribution	sexe	âge	ancienneté	niveau_formation
1	21894.4	F	42	3	B
2	38539.2	M	54	10	B
3	38177.6	M	47	10	A
4	38738.4	M	47	1	B
5	36481.6	M	44	5	B
6	35226.4	M	42	10	A
7	15516.0	M	30	5	A
8	15516.0	F	52	6	A
9	30499.2	M	48	8	A
10	15180.0	F	58	4	A
11	38539.2	M	46	4	C
12	42812.0	M	36	8	C
13	47035.2	M	49	10	B




EXEMPLE D'HISTOGRAMME

- Dans le cas de **variables continues** (mais aussi pour des variables discrètes qui prennent beaucoup de valeurs) :
 - On découpe l'intervalle de variation en k sous-intervalles
 - Chacun de ces intervalles est appelé **classe (bin)**
 - Il est possible de calculer les fréquences pour les classes
 - On peut représenter l'histogramme pour les classes

salarié	rétribution	sexe	âge	ancienneté	niveau_formation
1	21894.4	F	42	3	B
2	38539.2	M	54	10	B
3	38177.6	M	47	10	A
4	38738.4	M	47	1	B
5	36481.6	M	44	5	B
6	35226.4	M	42	10	A
7	15516.0	M	30	5	A
8	15516.0	F	52	6	A
9	30499.2	M	48	8	A
10	15180.0	F	58	4	A
11	38539.2	M	46	4	C
12	42812.0	M	36	8	C
13	47035.2	M	49	10	B



Indicateurs statistiques de position





INDICATEUR DE POSITION

- Un **indicateur de position** est une valeur (nombre réel) permettant de **situer** les valeurs d'une série statistique d'une variable quantitative
- Il peut s'agir d'un **indicateur de tendance centrale** (moyenne, médiane, etc.) ou d'une **valeur décentrée** comme le maximum ou le minimum de la série
- À noter : ils se distinguent des **indicateurs de dispersion** qui décrivent la **variabilité** des valeurs de la série


MODE

- Le **mode** est la **valeur la plus fréquente**
 - ⇒ c'est la valeur la plus « *à la mode* »



Distributions bimodales

- On appelle distribution **unimodale** une distribution présentant un seul mode
- Une distribution **multimodale** est une distribution présentant plusieurs modes
- Elle est souvent le reflet d'une population composée de plusieurs sous-populations distinctes



MOYENNE

- La notion de moyenne est historiquement reliée à celle **de valeur intermédiaire**
- Elle correspond à une répartition « équitable » de la grandeur mesurée sur tous les individus
 - C'est-à-dire : cumuler les valeurs d'une liste puis chercher à obtenir le même résultat en cumulant plusieurs fois la même valeur
- Par défaut, il s'agit de la **moyenne arithmétique**, qui se calcule comme la somme des termes de la liste, divisée par le nombre de termes

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$



- D'autres moyennes peuvent être plus adaptées selon les contextes :
 - Moyenne pondérée : $\bar{X}_w = \frac{\sum_{i=1}^n x_i \cdot w_i}{\sum_{i=1}^n w_i}$
 - Moyenne géométrique si les données ne sont pas des quantités additives (exemples : taux de croissance, ratios) : $G = \sqrt[n]{\prod_{i=1}^n x_i}$
 - Quadratique pour des mesures d'erreur par exemple (amplifie l'impact des grandes valeurs) : $M_Q = \sqrt{\frac{\sum_{i=1}^n x_i^2}{n}}$
- La moyenne ne peut se concevoir que pour une variable quantitative
 - $\Rightarrow$ on ne peut pas faire le total des valeurs d'une variable qualitative

MÉDIANE

- La médiane est la valeur qui sépare notre échantillon en deux groupes égaux, après l'avoir trié par ordre croissant
- Plus précisément, il y a autant d'individus pour lesquels on a observé une valeur supérieure à la médiane que d'individus pour lesquels on a observé une valeur inférieure à la médiane
- Pour déterminer la médiane d'un échantillon ou d'une population (méthode simple) :
 1. On classe les individus par ordre croissant
 2. On prend celui du milieu si nous avons un nombre impair de valeurs
 3. On prend la moyenne arithmétique des deux valeurs du milieu sinon

MODE, MOYENNE, MÉDIANE

Exemple



FRÉQUENCES CUMULÉES

- X : variable quantitative discrète ou continue classée dont l'intervalle de variation a été divisé en k classes
- L'**effectif cumulé** de la i -ème classe, où $i = 1, 2, \dots, k$ est le nombre N_i d'individus pour lesquels la variable X prend une valeur au plus égale à la borne supérieure de la classe i , donc :

$$N_i = \sum_{j=1}^i n_j$$


- Où n_j est la fréquence absolue (effectif) de la classe j
- La **fréquence cumulée** de la i -ème classe est définie comme ceci :

$$F_i = \frac{N_i}{N} = \sum_{j=1}^i f_j$$

- Où N est l'effectif total (c'est-à-dire N_k) et f_j la fréquence relative de la classe j (c'est-à-dire $\frac{n_j}{N}$)

FONCTION CUMULATIVE


- Dans le même esprit, il est possible de définir la **fonction cumulative** (qu'on appelle aussi **fonction de répartition**)
- Elle donne, pour tout nombre réel t , le pourcentage, noté par $F(t)$, des individus de la population pour lesquels on a observé une valeur de la variable X inférieure ou égale à t .
- Propriétés de la fonction cumulative $F(t)$:
 - Elle est croissante : si $t_1 \leq t_2$, on a $F(t_1) \leq F(t_2)$.
 - Elle vaut 0 pour tout nombre réel t inférieur à x_{min} , où x_{min} désigne la valeur minimale observée dans les données.
 - Elle est égale à 1 pour tout nombre réel t supérieur à x_{max} , où x_{max} désigne la valeur maximale observée dans les données.
- Si l'échantillonnage est bien fait, la courbe des fréquences cumulées de l'échantillon va approcher la fonction de répartition théorique
 - $\Rightarrow$ plus la taille de l'échantillon augmente, plus la fréquence cumulée devient une estimation précise de la fonction de répartition



QUANTILES, QUARTILES


- La notion de **quantile** généralise la médiane
- Le quantile d'ordre α permet de diviser la population étudiée en deux sous-groupes dont les effectifs sont respectivement $\alpha\%$ et $(1 - \alpha)\%$ les effectifs de la population initiale
 - La médiane est le quantile d'ordre $\alpha = 0.5$
- On note x_α la valeur du quantile d'ordre α
- Lorsque X est continue, on peut déterminer x_α au moyen de l'égalité $F(x_\alpha) = \alpha$
- Les **quartiles** de X sont ses trois quantiles $x_{0.25}$, $x_{0.50}$ et $x_{0.75}$:
 - $Q1 = x_{0.25}$, s'appelle le premier quartile; un quart des valeurs prises par X sont inférieures ou égales à $Q1$
 - $Q2 = x_{0.50}$ est la médiane
 - $Q3 = x_{0.75}$ s'appelle le troisième quartile ; un quart des valeurs prises par X sont supérieures ou égales à $Q3$

Variable discrète




A histogram showing the distribution of 'réttribution' (remuneration). The x-axis ranges from 15,000 to 50,000. The y-axis shows frequency from 0 to 16. Five vertical lines indicate quantiles: Q10 (dashed blue), Q25 (solid red), Q50 (solid green), Q75 (solid cyan), and Q90 (dashed magenta). The distribution is right-skewed, with a peak frequency of 17 at the 38,000-40,000 range.

Quantile	Approximate Value
Q10	17,500
Q25	26,000
Q50	35,000
Q75	39,000
Q90	42,000




Indicateurs statistiques de dispersion



INDICATEURS DE DISPERSION

- Un **indicateur de dispersion** mesure la **variabilité** des valeurs d'une série statistique
- Il est **toujours positif** et d'autant plus grand que les valeurs de la série sont étalées
- Ces indicateurs complètent l'information apportés par les indicateurs de position
- Les plus courants sont : l'**étendue**, la **variance**, l'**écart-type** ou encore l'**écart interquartile**.

- L'étendue de la variable quantitative X est la différence entre la plus grande et la plus petite des valeurs observées
- Par exemple, dans l'observation des âges des employés d'une entreprise
 - Étendue = $61 - 30 = 31$ ans



VARIANCE ET ÉCART-TYPE

- La variance d'une variable X est, par définition, la moyenne arithmétique des carrés des écarts à la moyenne arithmétique :

$$\text{Var}(X) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$


- Élever au carré permet :
 - D'éviter la somme nulle (si on calcule uniquement la moyenne des écarts à la moyenne)
 - Amplifier les gros écarts
 - Garantir certaines propriétés comme la dérivabilité
- L'écart-type de la variable X est, par définition, la racine carrée de la variance de cette variable :

$$\sigma_X = \sqrt{\text{Var}(X)}$$


VARIANCE ET ÉCART-TYPE

Exemple

Société 1



Société 2



- Étendue :
 - Société 1 : 33 844 €
 - Société 2 : 81 120 €
- Écart-type :
 - Société 1 : 8 975,09€
 - Société 2 : 24 321,10€



ÉCART INTERQUARTILE

- L'**écart interquartile** (*EI*) est une mesure de dispersion qui s'obtient en faisant la différence entre le troisième (75%) et le premier quartile (25%) :

$$EI = Q_3 - Q_1$$

- En effet, les valeurs Q1 et Q3 délimitent une plage au sein de laquelle 50% des valeurs de X sont concentrées
- Plus l'écart interquartile est grand, plus X est dispersée

- Écart interquartile :
 - Société 1: 12 705.6€
 - Société 2: 39 996.0€




UTILISATION EN DATA SCIENCE ET MACHINE LEARNING


- Analyse préliminaire des données (e.g., identification des *outliers*), visualisation
- Pré-traitement des données (e.g., standardisation pour pouvoir comparer des variables)
- Clustering *k-means* :
 - Étant donné un ensemble de n points $x_1, x_2, \dots, x_n$, on cherche à partitionner les n points en k ensembles $S = \{S_1, S_2, \dots, S_k\}$ tels que

$$\arg \min_S \sum_{i=1}^k \sum_{x_j \in S_i} \|x_j - \mu_i\|^2$$

- Où μ_i qui est le centre des points du cluster S_i



Statistiques multivariées



COVARIANCE

- Dans le cas de tableaux de données (i.e., jeu de données) **multivariés** (plusieurs variables), il est possible d'utiliser des indicateurs pour étudier l'existence de liens statistique entre variables
- La **covariance** mesure le degré de variabilité conjointe de deux variables
- Elle généralise la variance en plusieurs dimensions via les matrices de covariances (on calcule la covariance pour toutes les paires de variables)




- Notons $(x_1, x_2, \dots, x_N)$ et $(y_1, y_2, \dots, y_N)$ les valeurs des variables X et Y pour une population de N individus :

$$Cov(X, Y) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x}) \cdot (y_i - \bar{y})$$

- À noter que $Cov(X, X) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2 = Var(X)$

- Interprétation :

- $Cov(X, Y) < 0$: si X augmente, Y diminue
- $Cov(X, Y) > 0$: si X augmente, Y augmente
- $Cov(X, Y) \approx 0$: pas de relation linéaire entre X et Y (attention, cela **ne** signifie **pas** que X et Y sont indépendantes)




CORRÉLATION LINÉAIRE

- La **corrélation** entre plusieurs variables statistiques est une notion de liaison
- On normalise la covariance par le produit des écarts-types
- **Coefficient de corrélation linéaire (Corrélation de Pearson)** : mesure le degré de liaison linéaire entre deux variables


$$R(X, Y) = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

- Il est toujours compris entre -1 et $+1$
- Attention :
 - Si $R = 1$, cela ne signifie pas que si X augmente fortement, Y augmente également fortement !
 - Cela signifie uniquement que $Y = aX + b$ (où a et b sont des constantes). Dit autrement, je peux parfaitement prédire Y à partir de X




CORRÉLATION LINÉAIRE

- Interprétation du coefficient de corrélation linéaire :
 - $0,8 \leq R \leq 1$ ou $-1 \leq R \leq -0,8$: parfaite ou corrélation très forte
 - $0,6 \leq R \leq 0,8$ ou $-0,8 \leq R \leq -0,6$: forte corrélation
 - $0,4 \leq R \leq 0,6$ ou $-0,6 \leq R \leq -0,4$: corrélation modérée
 - $0,2 \leq R \leq 0,4$ ou $-0,4 \leq R \leq -0,2$: faible corrélation
 - $-0,2 \leq 0 \leq 0,2$: absente ou très faible corrélation




CORRÉLATION LINÉAIRE

- Si la relation entre les variables X et Y n'est pas linéaire, $R(X, Y)$ peut être nul (ou proche de 0) malgré une très forte dépendance curvilinéaire
- Donc $R(X, Y) \approx 0$ n'implique pas que X et Y sont indépendantes car d'autres types de corrélation sont possibles




- $R(X, Y)$ peut être très élevé même sans relation linéaire entre X et Y (voir le [quartet d'Anscombe](#))




CORRÉLATION LINÉAIRE

Exemple

salarié	rétribution	sexe	âge	ancienneté	niveau_formation
1	21894.4	F	42	3	B
2	38539.2	M	54	10	B
3	38177.6	M	47	10	A
4	38738.4	M	47	1	B
5	36481.6	M	44	5	B
6	35226.4	M	42	10	A
7	15516.0	M	30	5	A
8	15516.0	F	52	6	A
9	30499.2	M	48	8	A
10	15180.0	F	58	4	A
11	38539.2	M	46	4	C
12	42812.0	M	36	8	C
13	47035.2	M	49	10	B
...					



$$R(\text{age, salaire}) = 0.376112 \text{ (présence d'outliers)}$$




$$R(\text{ancienneté, salaire}) = 0.551464$$

CORRÉLATION N'EST PAS CAUSALITÉ

- Le fait que deux variables soient fortement corrélées ne démontre pas qu'il existe une relation de causalité entre l'une et l'autre
- Exemple : la vente de sandales de plages est corrélée au nombre de noyades sur les plages


CORRÉLATION N'EST PAS CAUSALITÉ

- Le fait que deux variables soient fortement corrélées ne démontre pas qu'il existe une relation de causalité entre l'une et l'autre
- Exemple : la vente de tongs est corrélée au nombre de noyades sur les plages
- Autre exemple :
 - Coefficient de corrélation de 86% entre les deux courbes
 - La dette du Bhoutan diminue soudainement après l'Oscar de Julia Roberts Roberts
- Coïncidence ?




CORRÉLATION N'EST PAS CAUSALITÉ

- Le fait que deux variables soient « fortement corrélées » ne démontre pas qu'il existe une relation de causalité entre l'une et l'autre
- Exemple : la vente de tongs est corrélée au nombre de noyades sur les plages
- Autre exemple :
 - Coefficient de corrélation de 86% entre les deux courbes
 - La dette du Bhoutan diminue soudainement après l'Oscar de Julia Roberts Roberts ⇒ exemple type de l'erreur logique « Post hoc ergo propter hoc » (« à la suite de cela, donc à cause de cela »)
- Coïncidence ? Je ne pense pas !




CORRÉLATION N'EST PAS CAUSALITÉ

- Le fait que deux variables soient « fortement corrélées » ne démontre pas existe une relation de causalité entre l'une et l'autre
- Exemple : la vente de sandales de plages est corrélée au nombre de noyades sur les plages
- Le raisonnement à ne jamais faire peut être résumé ainsi :
 - — L'événement Tong est corrélé à l'événement Noyade. Donc Tong cause Noyade.
- Il y a une multitude d'explications possibles à une corrélation :
 - Noyade peut être la cause de Tong
 - D'autres facteurs inconnus (nombre de personnes dans la station balnéaire, vacances, chaleur, etc.) peuvent-être des causes (totales ou partielles) communes à Noyade et Tong
 - Une simple coïncidence



Test du χ^2



- Le test du χ^2 (ou chi-deux, khi-deux) est un test d'hypothèses statistiques
- Utilisé en général pour mesurer comment un modèle théorique (population) se compare à des observations (échantillon)
- Il mesure la différence entre les fréquences observées et attendues des résultats d'un ensemble d'événements ou de variables
- Utilisé pour des variables catégorielles

$$\chi^2 = \sum_{i \in \mathcal{C}} \frac{(O_i - E_i)^2}{E_i}$$

- $\mathcal{C}$: ensemble des catégories
- E = fréquence attendue
- O = fréquence observée

- Utilisé pour trois tâches différentes:
 - le test du χ^2 d'**ajustement** (ou d'**adéquation**) qui compare globalement la distribution observée dans un échantillon à une distribution théorique (population)
 - le test du χ^2 d'**indépendance** qui teste si deux variables catégorielles sont indépendantes
 - le test du χ^2 d'**homogénéité** qui teste si des échantillons sont issus d'une même population
- Nous allons nous concentrer sur le test du χ^2 d'indépendance
- C'est un peu l'équivalent de la corrélation pour variables catégorielles

TEST DU χ^2 D'INDÉPENDANCE

- Données : deux variables catégorielles X et Y
- X est répartie en l classes possibles : $A_1, A_2, \dots, A_l$ et Y est répartie en c classes possibles : $B_1, B_2, \dots, B_c$
- Nous avons au total n observations
- Hypothèse testée : les variables X et Y sont indépendantes
- Nous allons créer le **tableau de contingence** avec les effectifs « croisés » des deux variables
 - $n_{i,j}$: nombre d'observations qui ont donné à la fois A_i pour la variable X et B_j pour la variable Y

	B_1	...	B_j	...	B_c
A_1	n_{11}	...	n_{1j}		n_{1c}
...					
A_i	n_{i1}		n_{ij}		n_{ic}
...					
A_l	n_{l1}		n_{lj}		n_{lc}

TEST DU χ^2 D'INDÉPENDANCE

- Nous allons créer le **tableau de contingence** avec les effectifs « croisés » des deux variables
 - $n_{i,j}$: nombre d'observations qui ont donné à la fois A_i pour la variable X et B_j pour la variable Y
- On borde le tableau avec le calcul des effectifs marginaux : les sommes des termes par lignes L_i et par colonnes C_c
 - ⇒ Il s'agit des observations totales de chaque classe A_i ou B_j

	B_1	...	B_j	...	B_c	
A_1	n_{11}	...	n_{1j}		n_{1c}	L_1
...						...
A_i	n_{i1}		n_{ij}		n_{ic}	L_i
...						...
A_l	n_{l1}		n_{lj}		n_{lc}	L_l
	C_1	...	C_j	...	C_c	

TEST DU χ^2 D'INDÉPENDANCE

- Nous allons créer le **tableau de contingence** avec les effectifs « croisés » des deux variables
 - $n_{i,j}$: nombre d'observations qui ont donné à la fois A_i pour la variable X et B_j pour la variable Y
- On calcule les « effectifs théoriques »
 - Le nombre d'observations pour chaque combinaison de classes A_i et B_j si X et Y étaient indépendantes
 - $$e_{ij} = \frac{L_i \times C_j}{n}$$

	B_1	...	B_j	...	B_c	
A_1	n_{11}	...	n_{1j}		n_{1c}	L_1
...						...
A_i	n_{i1}		n_{ij}		n_{ic}	L_i
...						...
A_l	n_{l1}		n_{lj}		n_{lc}	L_l
	C_1	...	C_j	...	C_c	

TEST DU χ^2 D'INDÉPENDANCE

- Nous allons créer le **tableau de contingence** avec les effectifs « croisés » des deux variables
 - $n_{i,j}$: nombre d'observations qui ont donné à la fois A_i pour la variable X et B_j pour la variable Y

$$\chi^2 = \sum_{i=1}^L \sum_{j=1}^C \frac{(n_{ij} - e_{ij})^2}{e_{ij}}$$

	B_1	...	B_j	...	B_c	
A_1	n_{11}	...	n_{1j}		n_{1c}	L_1
...						...
A_i	n_{i1}		n_{ij}		n_{ic}	L_i
...						...
A_l	n_{l1}		n_{lj}		n_{lc}	L_l
	C_1	...	C_j	...	C_c	

TEST DU χ^2 D'INDÉPENDANCE

En fonction du nombre de degrés de liberté (qu'on lit sur la première colonne) et du risque d'erreur α (qu'on lit sur la première ligne), on trouve la valeur de l'écart χ^2 qui possède la probabilité α d'être dépassée.

- On compare la valeur obtenue avec une valeur « critique »
 - On cherche la valeur critique χ^2_{α} dans une *table de la loi du χ^2* à $(L - 1) \times (C - 1)$ degrés de liberté (on prend généralement 0,05 comme risque d'écart)
 - Si $\chi^2 < \chi^2_{\alpha}$ on accepte l'hypothèse : X et Y sont indépendantes
 - Si $\chi^2 > \chi^2_{\alpha}$ on rejette l'hypothèse : X et Y ne sont pas indépendantes
 - La valeur χ^2 observée montre que les effectifs observés sont trop différents des effectifs théoriques pour que ce soit juste de la chance, cette différence est due à une liaison entre X et Y
- Vérification *a posteriori* des conditions d'application : il faut que les effectifs théoriques vérifient $e_{ij} > 5$ pour tous i, j , autrement nous n'avons pas assez d'informations

	0.10	0.05	0.01	0.001
1	2.706	3.841	6.635	10.828
2	4.605	5.991	9.210	13.816
3	6.251	7.815	11.345	16.266
4	7.779	9.488	13.277	18.467
5	9.236	11.070	15.086	20.515
6	10.645	12.592	16.812	22.458
7	12.017	14.067	18.475	24.322
8	13.362	15.507	20.090	26.124
9	14.684	16.919	21.666	27.877
10	15.987	18.307	23.209	29.588
11	17.275	19.675	24.725	31.264
12	18.549	21.026	26.217	32.909
13	19.812	22.362	27.688	34.528
14	21.064	23.685	29.141	36.123
15	22.307	24.996	30.578	37.697
16	23.542	26.296	32.000	39.252
17	24.769	27.587	33.409	40.790
18	25.989	28.869	34.805	42.312
19	27.204	30.144	36.191	43.820
20	28.412	31.410	37.566	45.315
21	29.615	32.671	38.932	46.797
22	30.813	33.924	40.289	48.268
23	32.007	35.172	41.638	49.728
24	33.196	36.415	42.980	51.179
25	34.382	37.652	44.314	52.620
30	40.26	43.77	50.89	59.70
35	46.06	49.80	57.34	66.62
40	51.81	55.76	63.69	73.40
45	57.51	61.66	69.96	80.08
50	63.17	67.50	76.15	86.66
60	74.40	79.08	88.38	99.61
70	85.53	90.53	100.43	112.32
80	96.58	101.88	112.33	124.84
90	107.57	113.15	124.12	137.21
100	118.50	124.34	135.81	149.45

EXEMPLE

- Pour comparer l'efficacité de deux médicaments agissant sur la même maladie, mais aux prix très différents, la Sécurité Sociale a effectué une enquête sur les guérisons obtenues en suivant chacun des traitements
- Nous devons vérifier s'il existe un lien entre le prix du médicament et le taux de guérison

	Date traitement	Département	Prix médicament	Guérison
1	12/07/2020	02	Bon marché	Oui
2	16/03/2019	33	Bon marché	Non
3	24/11/2020	24	Cher	Non
4	02/09/2019	13	Cher	Oui
5	11/06/2020	30	Bon marché	Non
...	...	...	...	...

EXEMPLE

- Tableau de contingence et effectifs marginaux

	Cher	Bon marché	Total
Guérison	$n_{11} = 44$	$n_{1,2} = 156$	200
Non guérison	$n_{21} = 7$	$n_{22} = 43$	50
Total	51	199	250

EXEMPLE

- Tableau de contingence et effectifs marginaux

	Cher	Bon marché	Total
Guérison	$n_{11} = 44$	$n_{1,2} = 156$	200
Non guérison	$n_{21} = 7$	$n_{22} = 43$	50
Total	51	199	250

- Calcul des effectifs théoriques :

- $e_{11} = \frac{200 \times 51}{250} = 40,8$
- $e_{12} = \frac{200 \times 199}{250} = 159,2$
- $e_{21} = \frac{50 \times 51}{250} = 10,2$
- $e_{22} = \frac{199 \times 50}{250} = 39,8$

EXEMPLE

- Tableau de contingence et effectifs marginaux

	Cher	Bon marché	Total
Guérison	$n_{11} = 44$	$n_{1,2} = 156$	200
Non guérison	$n_{21} = 7$	$n_{22} = 43$	50
Total	51	199	250

- Calcul des effectifs théoriques :

- $$e_{11} = \frac{200 \times 51}{250} = 40,8$$
- $$e_{12} = \frac{200 \times 199}{250} = 159,2$$
- $$e_{21} = \frac{50 \times 51}{250} = 10,2$$
- $$e_{22} = \frac{199 \times 50}{250} = 39,8$$

- Calcul du $\chi^2 = \sum_{i=1}^L \sum_{j=1}^C \frac{(n_{ij} - e_{ij})^2}{e_{ij}} = \frac{(44 - 40,8)^2}{40,8} + \frac{(156 - 159,2)^2}{159,2} + \frac{(10,2 - 7)^2}{10,2} + \frac{(43 - 39,8)^2}{39,8} \approx 1,56$

EXEMPLE

- Tableau de contingence et effectifs marginaux

	Cher	Bon marché	Total
Guérison	$n_{11} = 44$	$n_{1,2} = 156$	200
Non guérison	$n_{21} = 7$	$n_{22} = 43$	50
Total	51	199	250


- Calcul des effectifs théoriques :

- $$e_{11} = \frac{200 \times 51}{250} = 40,8$$
- $$e_{12} = \frac{200 \times 199}{250} = 159,2$$
- $$e_{21} = \frac{50 \times 51}{250} = 10,2$$
- $$e_{22} = \frac{199 \times 50}{250} = 39,8$$

- Calcul du $\chi^2 = \sum_{i=1}^L \sum_{j=1}^C \frac{(n_{ij} - e_{ij})^2}{e_{ij}} = \frac{(44 - 40,8)^2}{40,8} + \frac{(156 - 159,2)^2}{159,2} + \frac{(10,2 - 7)^2}{10,2} + \frac{(43 - 39,8)^2}{39,8} \approx 1,56$


- Table de référence (degré de liberté = 1) $\Rightarrow$ valeur de référence = 3,84 > 1,56 $\Rightarrow$ **pas de lien (variables indépendantes)**

Réduction de dimensionnalité




FLÉAU DE LA DIMENSION


- **Malédiction de la dimension** : lorsque le nombre de dimensions augmente, le nombre de configurations possibles augmente exponentiellement, et donc le nombre de configurations couvertes par un jeu de donnée décroît.
- Les données se retrouvent « isolées » et deviennent éparses
- Exemple en représentation discrète où chaque variable peut prendre 5 valeurs :



1 dimension
5 cas possibles
(5^1)



2 dimensions
25 cas possibles
(5^2)




3 dimensions
125 cas possibles
(5^3)



10 dimensions
9 765 625 cas possibles
(5^{10})

FLÉAU DE LA DIMENSION

- Exemple en représentation continue :



- Quand d tend vers $+\infty$, r tend vers 0 : cela signifie que les données de l'hypercube ne sont pas dans l'hypersphère mais dans les « coins » de l'hypercube
- Pour un algorithme de machine *learning*, cela signifie qu'en haute dimension, tous les points s'éparpillent tellement que le concept de « voisinage » s'effondre. Pour espérer retrouver une densité suffisante (et donc pouvoir entraîner correctement un modèle), il faudrait alors une quantité de données qui augmente de façon exponentielle !



FLÉAU DE LA DIMENSION

Les solutions :

- Augmenter le nombre d'échantillons
 - Pas toujours possible
 - Demande des quantités trop importantes en très grandes dimensions
- Réduire le nombre de dimension
 - Extraction de *features*
 - Sélection de *features*
 - Représentation dans un espace de moindre dimension (PCA, auto-encodeur, CNN, etc.)
- Ajouter de la connaissance métier
 - Peut permettre d'exclure des parties de l'espace non pertinentes à la tâche
 - Peut indiquer quelles parties de l'espace ont besoin d'être davantage échantillonnées

ANALYSE EN COMPOSANTES PRINCIPALES

- Technique utilisée pour des variables continues
- **Idée générale :** on cherche à plonger les données d'un espace original de dimension n dans un nouvel espace de dimension $k < n$ tout en maximisant la variance expliquée (c'est-à-dire en minimisant la perte d'information)
- On transforme donc des variables corrélées entre elles en nouvelles variables (moins nombreuses) décorrélées
- Comment ?
 1. Standardiser les données pour les rendre comparables
 2. Calcul de la matrice de corrélation
 3. Identifier l'axe capturant la plus grande dispersion (variance), c'est la composante principale PC_1
 4. Pour i allant de 2 à k :
 - a) Se placer dans l'espace orthogonal aux axes $PC_1, PC_2, \dots, PC_{i-1}$ (garantit l'absence de corrélation)
 - b) Dans cet espace, choisir l'axe maximisant la variance résiduelle et stocker sa valeur propre (quantité de variance capturée) λ_i
 5. Projeter les données dans ce nouvel espace de dimension k
- Si on ne veut pas fixer k ?
 - On calcule n composantes principales
 - On les classe en fonction des λ_i (éboulis des valeurs propres)
 - On garde uniquement les k premières composantes permettant d'atteindre un certain seuil t (i.e., $\sum_{i=1}^k \lambda_i \geq t$)



Source : OpenClassrooms


EXEMPLE

- **Exemple** : contrôle qualité de matières premières destinées à la fabrication de produits plastiques
- 3 mesures sont des valeurs de granulométrie (répartition de la taille des particules par plages)
- 3 autres sont les résultats d'analyses thermiques : analyse thermogravimétrique (TGA), calorimétrie différentielle (DSC) et analyse thermomécanique (TMA)
- Une désignation « adéquate » ou « médiocre » reflète l'opinion de l'ingénieur des procédés sur le rendement de ce lot de matériaux
- $N = 24$ échantillons, $K = 6$ variables quantitatives continues et 1 attribut externe qualitatif

	Lot number	Outcome	Size5	Size10	Size15	TGA	DSC	TMA
0	B370	Adequate	13.8	9.2	41.2	787.3	18.0	65.0
1	B880	Adequate	11.2	5.8	27.6	772.2	17.7	68.8
2	B452	Adequate	9.9	5.8	28.3	602.3	18.3	50.7
3	B287	Adequate	10.4	4.0	24.7	677.9	17.7	56.5
4	B576	Adequate	12.3	9.3	22.0	593.5	19.5	52.0


EXEMPLE

- Visualiser et analyser directement dans les 6 variables d'origine n'est pas simple
- Certains couples de variables montrent une corrélation, d'autres couples semblent montrer des variables décorrélées




EXEMPLE

- Possible d'appliquer une PCA
- Visualisation de l'importance des différentes composantes




- Projection des données dans les deux composantes principales : possible de distinguer bons et mauvais matériaux



AUTRES MÉTHODES

- Pour des variables non numériques :
 - **Analyse Factorielle des Correspondances** (AFC) : pour les variables qualitatives organisées dans un tableau de contingence
 - **Analyse des Correspondances Multiples** (ACM) : généralisation de l'AFC pour plus de deux variables qualitatives. On peut voir une ACM comme une AFC appliquée sur un « One-Hot Encoding » des catégories (transforme une catégorie en chiffre)
 - **Analyse Factorielle de Données Mixtes** (AFMD) : pour traiter à la fois des variables à la fois quantitatives et qualitatives
 - **Analyse Factorielle Multiple** (AFM) : pour les données complexes où les variables (qu'elles soient quantitatives ou qualitatives) sont structurées en groupes thématiques.

Tableaux de contingence



TABLEAUX DE CONTINGENCE

- Pour une analyse multivariée de variables **qualitatives/discrètes**, il est possible de créer un **tableau de contingence** afin d'estimer leur inter dépendance
- Tableau dénombrant les **modalités croisées** des deux variables X et Y
 - k lignes (nombre de modalités de X) et p colonnes (nombres de modalités de Y)
- Construit à partir des **effectifs croisés** :
 - n_{ij} : nombre d'individus ayant comme attribut la modalité i de X et la modalité j de Y
- On rajoute des marges où seront effectués les totaux :
 - Totaux en lignes $N_{i.}$: effectif de chaque modalité de X
 - Totaux en colonnes $N_{.j}$: effectif de chaque modalité de Y
 - Total général $N_{..}$: nombre d'individus étudiés

TABLEAUX DE CONTINGENCE

- Exemple :

	Y_1	...	Y_j	...	Y_p	Total
X_1	n_{11}	...	n_{1j}	...	n_{1p}	$N_{1.}$
...	...	...	...	...	...	...
X_i	n_{i1}	...	n_{ij}	...	n_{ip}	$N_{i.}$
...	...	...	...	...	...	...
X_k	n_{k1}	...	n_{kj}	...	n_{kp}	$N_{k.}$
Total	$N_{.1}$	...	$N_{.j}$	...	$N_{.p}$	$N_{..}$

Age/Malade	0 fois	1 fois	2 fois	3 fois	4 fois	Total
[20, 30[	4	2	2	1	1	10
[30, 40[	4	3	3	1	1	12
[40, 50[	7	2	1	0	0	10
[50, 60[	3	2	1	1	1	8
≥ 60	0	0	0	1	1	2
Total	18	9	7	4	4	42

Exemple issu de Wikipédia

TABLEAUX DE CONTINGENCE

- Pour mieux comparer lignes/colonnes, on construit deux tableaux avec les fréquences conditionnelles :
 - Tableaux des profils en lignes/colonnes
 - Fréquence conditionnelle de la colonne j : $f_{i|j} = \frac{n_{ij}}{N_{.j}}$
 - Fréquence conditionnelle de la ligne i : $f_{j|i} = \frac{n_{ij}}{N_{i.}}$
 - Les totaux ainsi normalisés deviennent les distributions marginales des variables X et Y

Par lignes :

	Y_1	...	Y_j	...	Y_p	Total
X_1	$f_{1 1}$		$f_{j 1}$		$f_{p 1}$	1
...						
X_i	$f_{1 i}$		$f_{j i}$		$f_{p i}$	1
...						
X_k	$f_{1 k}$		$f_{j k}$		$f_{p k}$	1
Total	$f_{.1}$		$f_{.j}$		$f_{.p}$	1

Par colonnes :

	Y_1	...	Y_j	...	Y_p	Total
X_1	$f_{1 1}$		$f_{1 j}$		$f_{1 p}$	$f_{1.}$
...						
X_i	$f_{i 1}$		$f_{i j}$		$f_{i p}$	$f_{i.}$
...						
X_k	$f_{k 1}$		$f_{k j}$		$f_{k p}$	$f_{k.}$
Total	1		1		1	1

TABLEAUX DE CONTINGENCE

Par lignes :

Age/Malade	0 fois	1 fois	2 fois	3 fois	4 fois	Total
[20, 30[	0,4	0,2	0,2	0,1	0,1	1
[30, 40[	$\frac{1}{3}$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{12}$	$\frac{1}{12}$	1
[40, 50[	0,7	0,2	0,1	0	0	1
[50, 60[	$\frac{3}{8}$	$\frac{1}{4}$	$\frac{1}{8}$	$\frac{1}{8}$	$\frac{1}{8}$	1
≥ 60	0	0	0	0,5	0,5	1
Total	$f_{.1}$	$f_{.2}$	$f_{.3}$	$f_{.4}$	$f_{.5}$	

$$P(2 \text{ fois} \mid [30, 40[)$$

Par colonnes :

Age/Malade	0 fois	1 fois	2 fois	3 fois	4 fois	Total
[20, 30[	$\frac{2}{9}$	$\frac{2}{9}$	$\frac{2}{7}$	$\frac{1}{4}$	$\frac{1}{4}$	$f_{1.}$
[30, 40[	$\frac{2}{9}$	$\frac{1}{3}$	$\frac{3}{7}$	$\frac{1}{4}$	$\frac{1}{4}$	$f_{2.}$
[40, 50[	$\frac{7}{18}$	$\frac{2}{9}$	$\frac{1}{7}$	0	0	$f_{3.}$
[50, 60[	$\frac{1}{6}$	$\frac{2}{9}$	$\frac{1}{7}$	$\frac{1}{4}$	$\frac{1}{4}$	$f_{4.}$
≥ 60	0	0	0	$\frac{1}{4}$	$\frac{1}{4}$	$f_{4.}$
Total	1	1	1	1	1	

$$P([30, 40[\mid 2 \text{ fois})$$



Humans & TECHNOLOGY
TO SCALE UP SUSTAINABLE PERFORMANCE